

Monitoramento de Alterações do Solo em Blumenau

Ana Carolina da Silva, Eduardo Brandt, Felipe Melio Tomelin e Gustavo Baroni Bruder

Introdução e contextualização do problema

O monitoramento das alterações do uso do solo e também de sua cobertura representa um desafio não só para a gestão territorial urbana mas também para entender onde as áreas de risco se encontram, já que é bem difícil analisar pessoalmente as regiões da cidade e também é inviável utilizar um monitoramento por satélite devido ao alto custo.

A necessidade de compreender e quantificar as mudanças na cobertura vegetal, na expansão das áreas urbanas torna-se importante para o planejamento sustentável do território e também para evitar construções em áreas indevidas, entre outras coisas que podem causar tragédias com a população. Métodos tradicionais de coleta de dados presencial, embora precisos, apresentam limitações significativas em termos de custo, tempo e capacidade de cobertura territorial. Neste contexto, o sensoriamento remoto serve como uma ferramenta poderosa, permitindo a análise sistemática e repetitiva de grandes extensões territoriais através de dados obtidos por satélites.

Um trabalho que contribuiu muito para entender como funciona o uso de índices de vegetação e como eles poderiam ajudar a identificar as mudanças no solo foi o trabalho de Cordovil et al. (2024).

Tabela comparativa

Este estudo compara três abordagens distintas de sensoriamento remoto aplicadas à detecção de mudanças no uso do solo: Godoy (2024), com redes neurais convolucionais; Notti et al. (2023), com NDVI e Google Earth Engine; e Cordovil et al. (2024), com uma revisão sobre o uso de técnicas como NDVI, IA e sensores multiespectrais em estudos ambientais. A análise destaca os métodos, dados utilizados e contribuições de cada trabalho para o monitoramento urbano e ambiental.

Artigo	Metodologia	Fonte de Dados	Resultados	Conclusões
Godoy (2024)UNESP	CNN U-Net + regras de mudança	WorldView-2, Guaratinguetá	Acurácia >89%, recall alto, baixa precisão	Eficaz em mudanças urbanas, mas muitos falsos positivos

Cordovil et al. (2024)	Revisão: NDVI, IA, Landsat, classificação supervisionada, drones	Diversos sensores e estudos de caso	Apresenta ampla gama de aplicações ambientais e urbanas	Sensoriamento remoto é essencial, especialmente com integração IA e geotecnologias
Notti et al. (2023) CNR Itália	NDVI variação + filtros morfológicos	Sentinel-2 + GEE + Imagens aéreas	Detecta deslizamentos >100 m ² , alta taxa de falsos positivos	Método rápido e acessível, útil como triagem pós-desastre

A análise comparativa entre os artigos de **Godoy (2024)**, **Notti et al. (2023)** e **Cordovil et al. (2024)** permitiu explorar diferentes abordagens de sensoriamento remoto voltadas à detecção de mudanças no uso e cobertura do solo. Os três trabalhos possuem o objetivo comum de utilizar dados de imagens orbitais e técnicas de reconhecimento de padrões para apoiar o monitoramento ambiental e urbano.

O artigo de Godoy (2024) aplica redes neurais convolucionais, especificamente a arquitetura U-Net, para segmentar elementos urbanos em imagens WorldView-2. Essa abordagem possui alta acurácia na classificação de construções e vegetação, porém, enfrentou limitações com falsos positivos na detecção de mudanças por causa das variações entre imagens capturadas em datas diferentes.

Por outro lado, Notti et al. (2023) propõem um método semi-automatizado baseado em variação do índice NDVI, junto com filtros geomorfológicos como declividade e distância de rios. O estudo foi realizado com imagens Sentinel-2 dentro do Google Earth Engine e foi eficaz para identificar deslizamentos de terra em grande escala, mas apresentou taxas altas de falsos positivos em regiões agrícolas e com muita floresta. Mesmo assim, o método demonstrou grande potencial para aplicações rápidas e em larga escala, especialmente em contextos de desastres naturais. Esse artigo reforçou para o trabalho prático realizado, o uso do NDVI como um indicador confiável de alterações da vegetação.

Já o artigo de Cordovil et al. (2024) têm uma revisão boa sobre o uso do sensoriamento remoto em estudos ambientais, abordando sensores ópticos, índices espectrais (NDVI, NDWI) e tecnologias emergentes como inteligência artificial e drones. O artigo possui aplicações reais, incluindo monitoramento de queimadas, desmatamento, urbanização e segurança alimentar, e destaca a importância da integração entre sensores e algoritmos para aumentar a eficiência na análise espacial. Em conjunto com o artigo de Notti et al (2023), esse artigo colaborou com uma visão de confiabilidade maior na junção dos índices de NDVI e NDWI trabalhando juntos.

Apesar das diferenças metodológicas, todos os estudos evidenciam a relevância do sensoriamento remoto como ferramenta para a compreensão e gestão do território. Seja em escala local (como no mapeamento urbano com CNNs) ou regional (como nas análises NDVI

no GEE), as técnicas discutidas uma ótima base para detectar transformações ambientais de forma eficiente e replicável, e por mais que o artigo de Godoy (2024) não tenha sido utilizado para extrair nenhuma técnica para o trabalho apresentado, seus resultados serviram de base para outras ferramentas serem exploradas.

Metodologia e construção da base de dados

Para o desenvolvimento deste estudo, utilizou-se imagens do satélite Sentinel-2, operado pela Agência Espacial Europeia (ESA), que fornece dados multiespectrais com resolução espacial de 10 metros e revisita temporal de 5 dias. A área de estudo foi definida através de um buffer circular de 5 quilômetros ao redor do ponto central de Blumenau (coordenadas -49.0661°, -26.9186°), abrangendo tanto o núcleo urbano quanto às áreas periféricas de interesse para análise.

O período temporal selecionado correspondeu ao mês de novembro de 2023. A implementação técnica foi realizada através da plataforma Google Earth Engine, que permite o processamento distribuído de grandes volumes de dados geoespaciais. O código desenvolvido estabelece a conexão com a coleção de imagens COPERNICUS/S2_SR_HARMONIZED:

```
coordenadas_blumenau = ee.Geometry.Point([-49.0661, -26.9186]).buffer(5000).bounds()
data_inicio = '2023-11-01'
data_fim = '2023-11-30'

imagem = ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED') \
    .filterBounds(coordenadas_blumenau) \
    .filterDate(data_inicio, data_fim) \
    .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 20)) \
    .median()
```

Esta abordagem garante a obtenção de uma imagem composta representativa do período, minimizando a interferência de nuvens e outras anomalias atmosféricas.

Fundamentação teórica dos índices espectrais

O uso de índices espectrais se baseia no fato de que diferentes materiais da superfície da Terra refletem a radiação eletromagnética de maneiras distintas. A vegetação saudável apresenta características espectrais distintivas: alta absorção na região do vermelho (aproximadamente 665 nm) devido à presença de clorofila, e alta reflectância na região do infravermelho próximo (842 nm) devido à estrutura celular das folhas. Esta assinatura espectral única permite a diferenciação entre vegetação, corpos d'água, solo exposto e áreas construídas.

O Índice de Vegetação por Diferença Normalizada (NDVI) representa o padrão consolidado para análise de cobertura vegetal. Sua formulação matemática $(NIR - RED) / (NIR + RED)$ estabelece uma relação normalizada que varia entre -1 e +1, onde valores próximos a +1 indicam vegetação densa e saudável, valores próximos a zero representam

solo exposto ou vegetação esparsa, e valores negativos caracterizam corpos d'água ou superfícies artificiais.

No contexto do projeto, o NDVI foi implementado através da função *normalizedDifference* do Google Earth Engine:

```
ndvi = imagem.normalizedDifference(['B8', 'B4']).rename('NDVI')
```

Paralelamente, o Índice de Água por Diferença Normalizada (NDWI) utiliza a formulação $(\text{GREEN} - \text{NIR}) / (\text{GREEN} + \text{NIR})$ para identificar corpos d'água, explorando a característica de alta absorção do infravermelho próximo pela água:

```
ndwi = imagem.normalizedDifference(['B3', 'B8']).rename('NDWI')
```

Índices alternativos e suas aplicações

Reconhecendo as limitações do NDVI em determinados contextos, particularmente a dependência de sensores infravermelhos que podem ser custosos, o estudo incorpora índices alternativos que utilizam exclusivamente bandas do espectro visível. O Índice de Vegetação Visível Resistente à Atmosfera (VARI) representa uma solução para esta limitação, utilizando a formulação $(\text{GREEN} - \text{RED}) / (\text{GREEN} + \text{RED} - \text{BLUE})$.

A implementação do VARI no código demonstra sua aplicação prática:

```
R = img[:, :, 0] # Banda vermelha
G = img[:, :, 1] # Banda verde
B = img[:, :, 2] # Banda azul

numerador = G - R
denominador = G + R - B
index_vari_aprimorado = apresentar_estatisticas(numerador, denominador, 'VARI Aprimorado')
```

O VARI apresenta vantagens significativas em ambientes com alta variabilidade atmosférica, como a região de Blumenau, já que muitas vezes o vale sofre com neblina e entre outras coisas que podem afetar as imagens obtidas. A inclusão da banda azul na formulação atua como um fator de correção atmosférica, reduzindo interferências causadas por vapores e aerossóis.

Complementarmente, o Índice Verde-Vermelho Diferencial Normalizado (NGRDI) oferece uma abordagem minimalista utilizando apenas as bandas verde e vermelha:

```
numerador = G - R
denominador = G + R
apresentar_estatisticas(numerador, denominador, 'NGRDI')
```

O Índice de Folha Verde (GLI) emprega uma formulação que enfatiza a resposta espectral verde, sendo particularmente sensível à vegetação jovem e gramíneas:

```

numerador = 2 * G - R - B
denominador = 2 * G + R + B
apresentar_estatisticas(numerador, denominador, 'GLI')

```

Desenvolvimento de índice customizado

Para otimizar a detecção de vegetação nas condições específicas da região de estudo, foi desenvolvido um índice customizado que incorpora pesos diferenciados para cada banda espectral:

```

numerador = (1.4 * G) - (1.0 * R) - (0.4 * B)
denominador = G + R + B
apresentar_estatisticas(numerador, denominador, 'Índice Customizado')

```

Os coeficientes 1.4, 1.0 e 0.4 foram estabelecidos através de análise empírica, visando maximizar a discriminação entre vegetação, áreas urbanas e corpos d'água característicos da região. O peso aumentado para a banda verde (1.4) enfatiza a resposta espectral da vegetação tropical, enquanto o fator reduzido para a banda azul (0.4) minimiza interferências atmosféricas.

Classificação automatizada e análise espacial

A classificação dos diferentes tipos de cobertura do solo foi implementada através do algoritmo K-means, uma técnica de aprendizado não supervisionado que agrupa pixels com características espectrais similares. A escolha de três clusters (`n_clusters=3`) baseou-se na expectativa de identificar as principais classes de cobertura: vegetação, áreas urbanas/solo exposto e corpos d'água.

```

kmeans = KMeans(n_clusters=3, random_state=42, n_init=10).fit(valid_pixels)
clustered[mask] = kmeans.labels_.reshape(np.sum(mask))

```

Adicionalmente, foi implementada uma classificação baseada em limiares empíricos do VARI, estabelecendo categorias específicas de cobertura do solo:

```

classified = np.zeros_like(index_vari_aprimorado)
classified[index_vari_aprimorado < -0.1] = 0 # Solo/água
classified[(index_vari_aprimorado ≥ -0.1) & (index_vari_aprimorado < 0.2)] = 1 # Vegetação baixa
classified[(index_vari_aprimorado ≥ 0.2) & (index_vari_aprimorado < 0.5)] = 2 # Vegetação moderada
classified[index_vari_aprimorado ≥ 0.5] = 3 # Vegetação densa

```

Esta abordagem de classificação por limiares permite uma interpretação direta dos valores dos índices, facilitando a identificação de diferentes intensidades de cobertura vegetal na área de estudo.

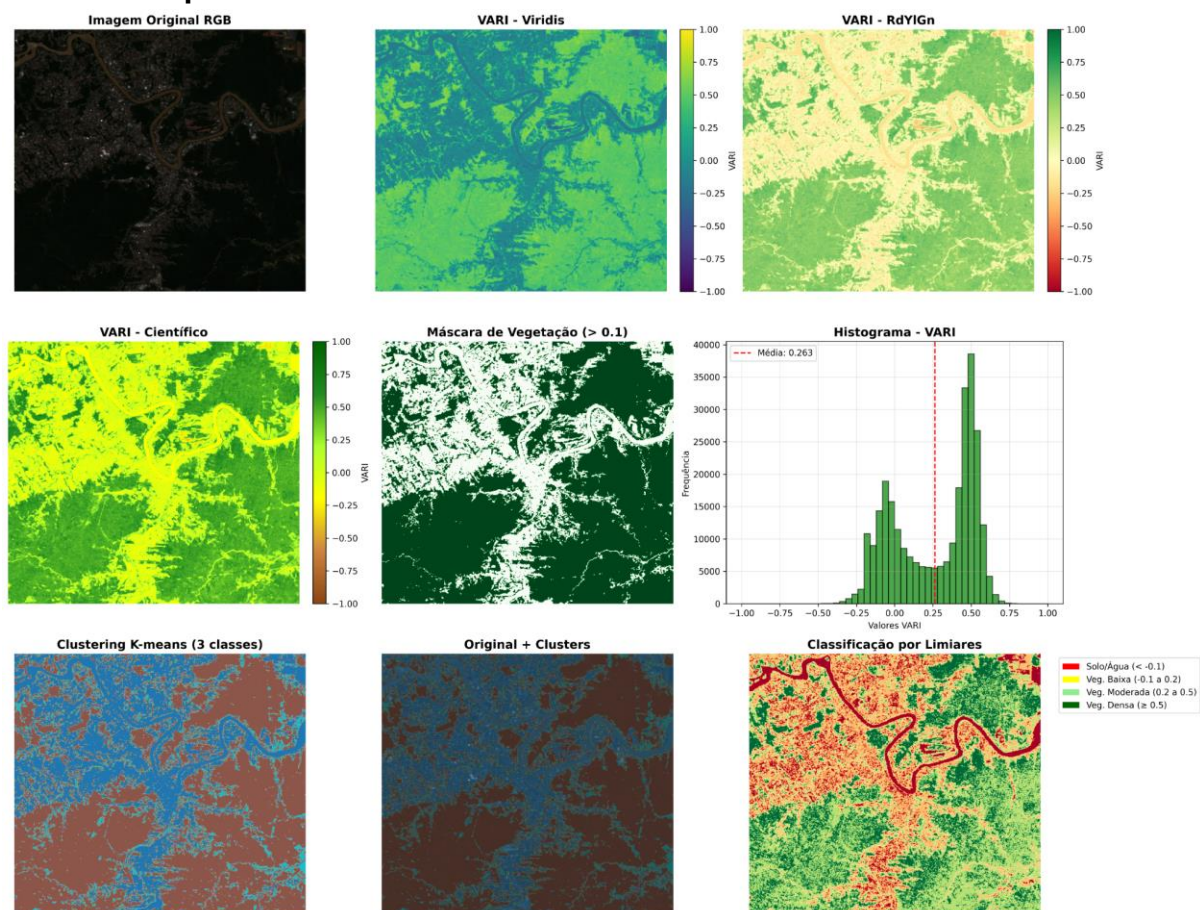
Visualização e interpretação dos resultados

O sistema de visualização implementado permite a análise comparativa dos diferentes índices através de mapas temáticos com esquemas de cores específicas. A utilização de paletas de cores personalizadas facilita a interpretação visual dos resultados:

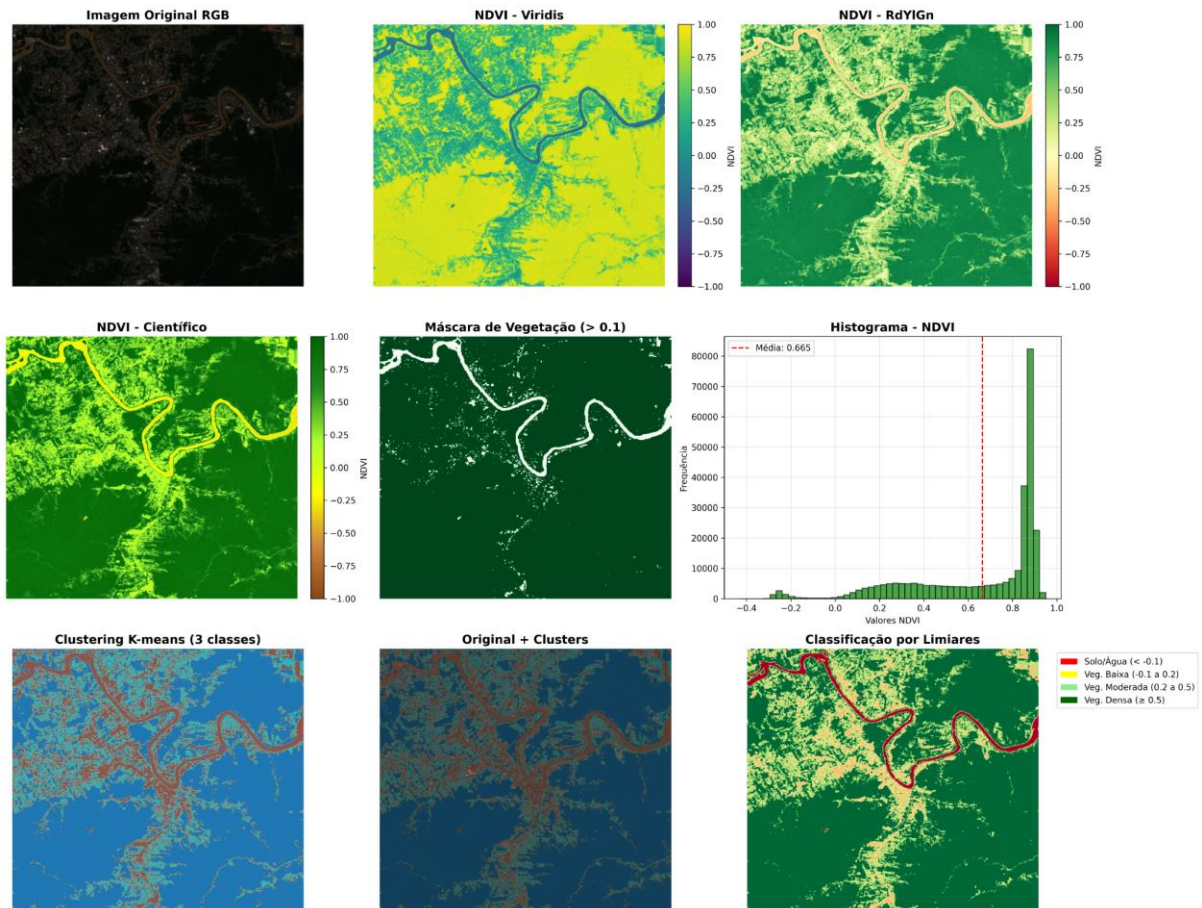
```
colors = ['#8B4513', '#CD853F', '#FFFF00', '#ADFF2F', '#228B22', '#006400']
```

Esta abordagem cromática estabelece uma progressão visual intuitiva, onde tons marrons representam solo exposto ou áreas urbanas, tons amarelos indicam vegetação esparsa, e tons verdes progressivamente mais intensos correspondem a vegetação moderada e densa.

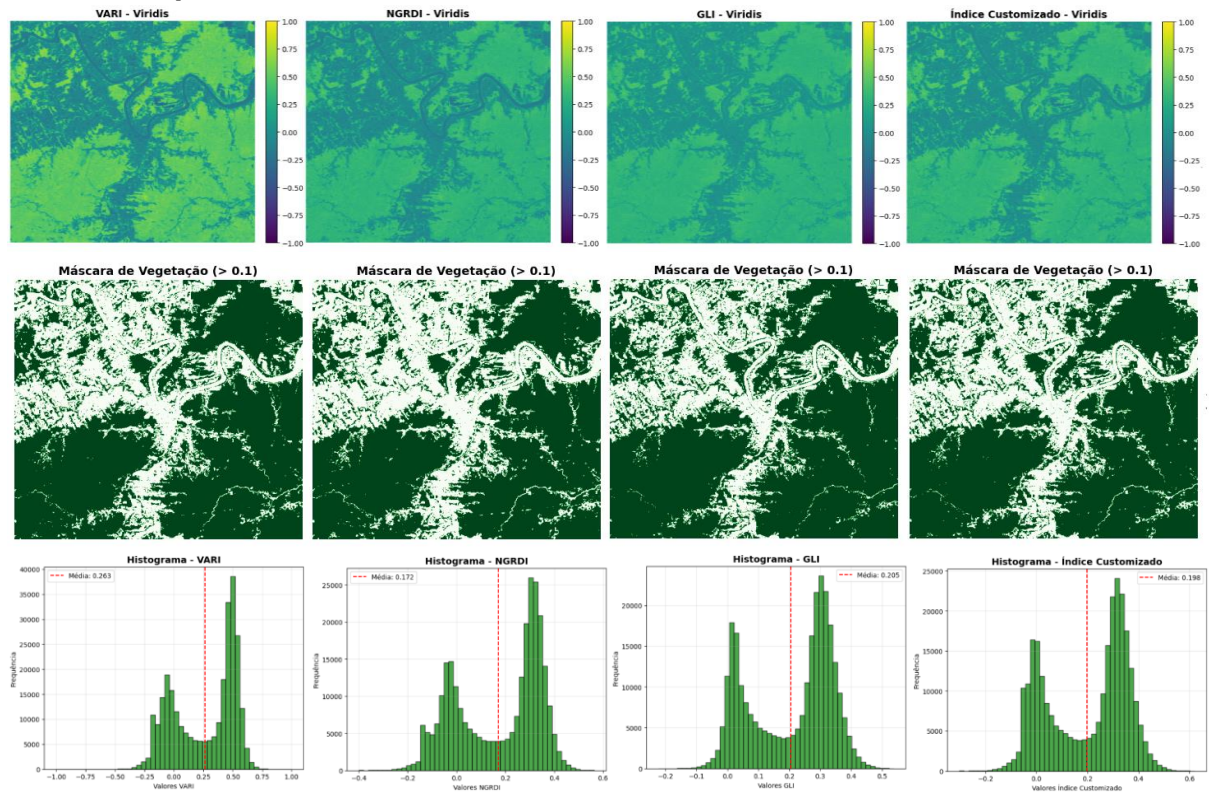
1. Exemplo de análise utilizando VARI




2. Exemplo de análise utilizando NDVI

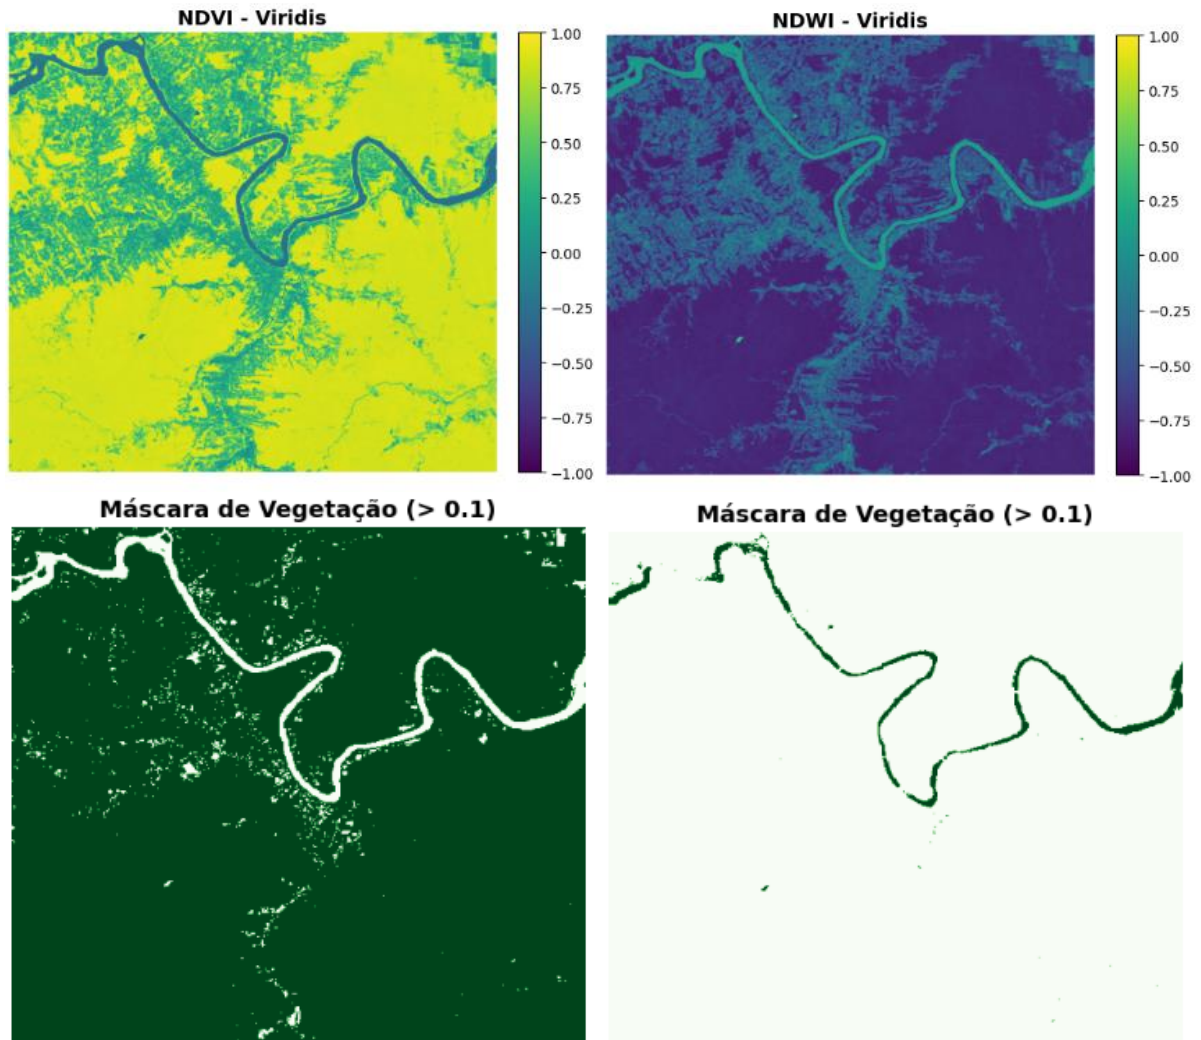


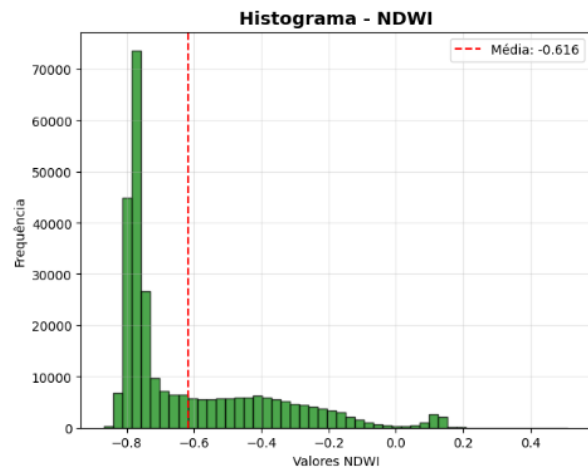

3. Comparativo entre os índices RGB





4. Comparativo entre os índices RGB + NIR (infravermelho)





Aplicações e perspectivas futuras

A metodologia desenvolvida oferece aplicações práticas significativas para o planejamento territorial de Blumenau, além de fornecer uma maneira de identificar a saúde da vegetação da região e também uma maneira para monitorar alterações no solo da cidade. A capacidade de quantificar e mapear alterações na cobertura vegetal pode subsidiar políticas de conservação ambiental e planejamento urbano sustentável.

Usar vários índices espectrais torna a análise mais confiável e ajuda a confirmar os resultados por diferentes métodos. Esta abordagem multi-índice é boa em ambientes urbanos complexos, onde a mistura de diferentes tipos de cobertura do solo pode gerar ambiguidades na classificação.

O desenvolvimento futuro desta pesquisa pode incorporar análises temporais mais extensas, permitindo a quantificação de taxas de mudança na cobertura do solo ao longo do tempo. A integração com dados socioeconômicos e climáticos pode enriquecer a compreensão dos processos que conduzem às alterações observadas, contribuindo para um planejamento territorial mais informado e sustentável.